HR_analytics_attrition

April 14, 2026

1 Patrones asociados a la rotación de personal

1.1 Importación de las librerías a utilizar

[26]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import optuna

from sklearn.model_selection import train_test_split, StratifiedKFold,␣
↪cross_val_score
from sklearn.ensemble import RandomForestClassifier
from sklearn.tree import plot_tree
from sklearn.metrics import classification_report, confusion_matrix,␣
↪ConfusionMatrixDisplay, roc_curve, auc
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder, LabelEncoder

from imblearn.over_sampling import SMOTENC
sns.set_theme(style="whitegrid", context="notebook")
```

1.2 Carga de los datos

[27]:
```
df = pd.read_csv("/kaggle/input/datasets/pavansubhasht/
↪ibm-hr-analytics-attrition-dataset/WA_Fn-UseC_-HR-Employee-Attrition.csv")
print(df.head(5))
```

```
   Age Attrition     BusinessTravel  DailyRate              Department  \
0   41       Yes      Travel_Rarely       1102                   Sales
1   49        No  Travel_Frequently        279  Research & Development
2   37       Yes      Travel_Rarely       1373  Research & Development
3   33        No  Travel_Frequently       1392  Research & Development
4   27        No      Travel_Rarely        591  Research & Development

   DistanceFromHome  Education EducationField  EmployeeCount  EmployeeNumber  \
```

```
0                 1          2  Life Sciences              1               1
1                 8          1  Life Sciences              1               2
2                 2          2          Other              1               4
3                 3          4  Life Sciences              1               5
4                 2          1        Medical              1               7

   …  RelationshipSatisfaction StandardHours  StockOptionLevel  \
0  …                         1            80                 0
1  …                         4            80                 1
2  …                         2            80                 0
3  …                         3            80                 0
4  …                         4            80                 1

   TotalWorkingYears  TrainingTimesLastYear WorkLifeBalance  YearsAtCompany  \
0                  8                      0               1               6
1                 10                      3               3              10
2                  7                      3               3               0
3                  8                      3               3               8
4                  6                      3               3               2

  YearsInCurrentRole  YearsSinceLastPromotion  YearsWithCurrManager
0                  4                        0                     5
1                  7                        1                     7
2                  0                        0                     0
3                  7                        3                     0
4                  2                        2                     2

[5 rows x 35 columns]
```

1.3 Inspección de los datos

[28]:
```python
print("Dimensiones:", df.shape)
print("\nInformación general:")
df.info()
```

```
Dimensiones: (1470, 35)

Información general:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 35 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Age                       1470 non-null   int64
 1   Attrition                 1470 non-null   object
 2   BusinessTravel            1470 non-null   object
 3   DailyRate                 1470 non-null   int64
 4   Department                1470 non-null   object
```

```
 5   DistanceFromHome          1470 non-null   int64
 6   Education                 1470 non-null   int64
 7   EducationField            1470 non-null   object
 8   EmployeeCount             1470 non-null   int64
 9   EmployeeNumber            1470 non-null   int64
 10  EnvironmentSatisfaction   1470 non-null   int64
 11  Gender                    1470 non-null   object
 12  HourlyRate                1470 non-null   int64
 13  JobInvolvement            1470 non-null   int64
 14  JobLevel                  1470 non-null   int64
 15  JobRole                   1470 non-null   object
 16  JobSatisfaction           1470 non-null   int64
 17  MaritalStatus             1470 non-null   object
 18  MonthlyIncome             1470 non-null   int64
 19  MonthlyRate               1470 non-null   int64
 20  NumCompaniesWorked        1470 non-null   int64
 21  Over18                    1470 non-null   object
 22  OverTime                  1470 non-null   object
 23  PercentSalaryHike         1470 non-null   int64
 24  PerformanceRating         1470 non-null   int64
 25  RelationshipSatisfaction  1470 non-null   int64
 26  StandardHours             1470 non-null   int64
 27  StockOptionLevel          1470 non-null   int64
 28  TotalWorkingYears         1470 non-null   int64
 29  TrainingTimesLastYear     1470 non-null   int64
 30  WorkLifeBalance           1470 non-null   int64
 31  YearsAtCompany            1470 non-null   int64
 32  YearsInCurrentRole        1470 non-null   int64
 33  YearsSinceLastPromotion   1470 non-null   int64
 34  YearsWithCurrManager      1470 non-null   int64
dtypes: int64(26), object(9)
memory usage: 402.1+ KB
```

1.4 Resumen estadístico descriptivo

1.4.1 Variables numéricas

[29]:
```
print(df.describe())
```

```
               Age    DailyRate  DistanceFromHome    Education  EmployeeCount  \
count  1470.000000  1470.000000       1470.000000  1470.000000         1470.0
mean     36.923810   802.485714          9.192517     2.912925            1.0
std       9.135373   403.509100          8.106864     1.024165            0.0
min      18.000000   102.000000          1.000000     1.000000            1.0
25%      30.000000   465.000000          2.000000     2.000000            1.0
50%      36.000000   802.000000          7.000000     3.000000            1.0
75%      43.000000  1157.000000         14.000000     4.000000            1.0
max      60.000000  1499.000000         29.000000     5.000000            1.0
```

```
       EmployeeNumber  EnvironmentSatisfaction   HourlyRate  JobInvolvement  \
count     1470.000000              1470.000000  1470.000000     1470.000000
mean      1024.865306                 2.721769    65.891156        2.729932
std        602.024335                 1.093082    20.329428        0.711561
min          1.000000                 1.000000    30.000000        1.000000
25%        491.250000                 2.000000    48.000000        2.000000
50%       1020.500000                 3.000000    66.000000        3.000000
75%       1555.750000                 4.000000    83.750000        3.000000
max       2068.000000                 4.000000   100.000000        4.000000

          JobLevel  …  RelationshipSatisfaction  StandardHours  \
count  1470.000000  …               1470.000000         1470.0
mean      2.063946  …                  2.712245           80.0
std       1.106940  …                  1.081209            0.0
min       1.000000  …                  1.000000           80.0
25%       1.000000  …                  2.000000           80.0
50%       2.000000  …                  3.000000           80.0
75%       3.000000  …                  4.000000           80.0
max       5.000000  …                  4.000000           80.0

       StockOptionLevel  TotalWorkingYears  TrainingTimesLastYear  \
count       1470.000000        1470.000000            1470.000000
mean           0.793878          11.279592               2.799320
std            0.852077           7.780782               1.289271
min            0.000000           0.000000               0.000000
25%            0.000000           6.000000               2.000000
50%            1.000000          10.000000               3.000000
75%            1.000000          15.000000               3.000000
max            3.000000          40.000000               6.000000

       WorkLifeBalance  YearsAtCompany  YearsInCurrentRole  \
count      1470.000000     1470.000000         1470.000000
mean          2.761224        7.008163            4.229252
std           0.706476        6.126525            3.623137
min           1.000000        0.000000            0.000000
25%           2.000000        3.000000            2.000000
50%           3.000000        5.000000            3.000000
75%           3.000000        9.000000            7.000000
max           4.000000       40.000000           18.000000

       YearsSinceLastPromotion  YearsWithCurrManager
count              1470.000000           1470.000000
mean                 2.187755              4.123129
std                  3.222430              3.568136
min                  0.000000              0.000000
25%                  0.000000              2.000000
50%                  1.000000              3.000000
```

```
75%                   3.000000              7.000000
max                  15.000000             17.000000

[8 rows x 26 columns]
```

1.4.2 Variables categóricos

[30]:
```python
print(df.describe(include="object"))
```

```
       Attrition BusinessTravel              Department EducationField Gender  \
count       1470           1470                    1470           1470   1470
unique         2              3                       3              6      2
top           No  Travel_Rarely  Research & Development  Life Sciences   Male
freq        1233           1043                     961            606    882

                JobRole MaritalStatus Over18 OverTime
count              1470          1470   1470     1470
unique                9             3      1        2
top     Sales Executive       Married      Y       No
freq                326           673   1470     1054
```

1.5 Descripción de las variables:

1.5.1 Variables demográficas y generales

Attrition:

```
- Indica si el empleado dejó la empresa durante el período de observación.
- Valores comunes:
    - Yes: El empleado dejó la empresa (renuncia, despido u otra forma de salida)
    - No: El empleado permanece en la empresa
```

Gender:

```
- Género del empleado.
```

MaritalStatus:

```
- Estado civil (Single, Married, Divorced).
```

Over18:

```
- Indica si el empleado es mayor de 18 años (normalmente siempre es "Yes").
```

EmployeeNumber:

```
- Identificador único del empleado.
```

EmployeeCount:

```
- Contador de empleados (normalmente siempre = 1, no aporta variabilidad).
```

1.5.2 Variables del puesto y la organización

Department:

- Departamento donde trabaja el empleado (Sales, Research & Development, HR).

JobRole:

- Rol específico del puesto (Sales Executive, Research Scientist, etc.).

JobLevel:

- Nivel jerárquico del puesto (1 = bajo, valores mayores = más senior).

BusinessTravel:

- Frecuencia de viajes laborales (Non-Travel, Travel_Rarely, Travel_Frequently).

OverTime:

- Indica si el empleado hace horas extra (Yes / No).

StandardHours:

- Horas estándar de trabajo (normalmente constante).

1.5.3 Variables salariales

DailyRate:

- Pago diario del empleado.

HourlyRate:

- Pago por hora.

MonthlyIncome:

- Ingreso mensual total.

MonthlyRate:

- Tarifa mensual (no necesariamente el sueldo).

PercentSalaryHike:

- Porcentaje de aumento salarial más reciente.

StockOptionLevel:

- Nivel de incentivos a largo plazo (rango de utilidades recibidas, planes de carrera, etc).

1.5.4 Educación y experiencia

Education:

```
- Nivel educativo (1 = bajo, 5 = alto).
```

EducationField:

```
- Área de estudio (Life Sciences, Marketing, Technical Degree, etc.).
```

NumCompaniesWorked:

```
- Número de empresas en las que trabajó anteriormente.
```

TotalWorkingYears:

```
- Total de años de experiencia laboral.
```

TrainingTimesLastYear:

```
- Número de capacitaciones recibidas el último año.
```

1.5.5 Ubicación y movilidad

DistanceFromHome:

```
- Distancia en km entre la casa y el trabajo.
```

BusinessTravel:

```
- Frecuencia de viajes laborales.
```

1.5.6 Satisfacción y compromiso (escalas ordinales)

Estas suelen ir de 1 (bajo) a 4 o 5 (alto):

EnvironmentSatisfaction:

```
    - Satisfacción con el ambiente laboral.
```

JobSatisfaction:

```
    - Satisfacción con el trabajo.
```

RelationshipSatisfaction:

```
    - Satisfacción con las relaciones laborales.
```

WorkLifeBalance:

```
    - Equilibrio vida-trabajo.
```

JobInvolvement:

- Nivel de involucramiento en el trabajo.

1.5.7 Desempeño y carrera

PerformanceRating:

- Calificación del desempeño laboral.

YearsAtCompany:

- Años trabajando en la empresa actual.

YearsInCurrentRole:

- Años en el rol actual.

YearsSinceLastPromotion:

- Años desde la última promoción.

YearsWithCurrManager:

- Años trabajando con el gerente actual.

1.6 Análisis de las variables

1.6.1 ¿Cómo influye los incentivos a largo plazo en la rotación de personal?

- Ganancia de utilidades, planes de carrera, etc

[31]:
```
import matplotlib.pyplot as plt
import seaborn as sns

stockopt_attrition = df.groupby(["StockOptionLevel","Attrition"])["DailyRate"].
 ↪size().reset_index(name="Counts")
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data=stockopt_attrition, x="StockOptionLevel", y="Counts",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Recuento de personas por el nivel de incentivos\n a largo plazo")
ax.grid(True)
fig.tight_layout()
plt.show()
```

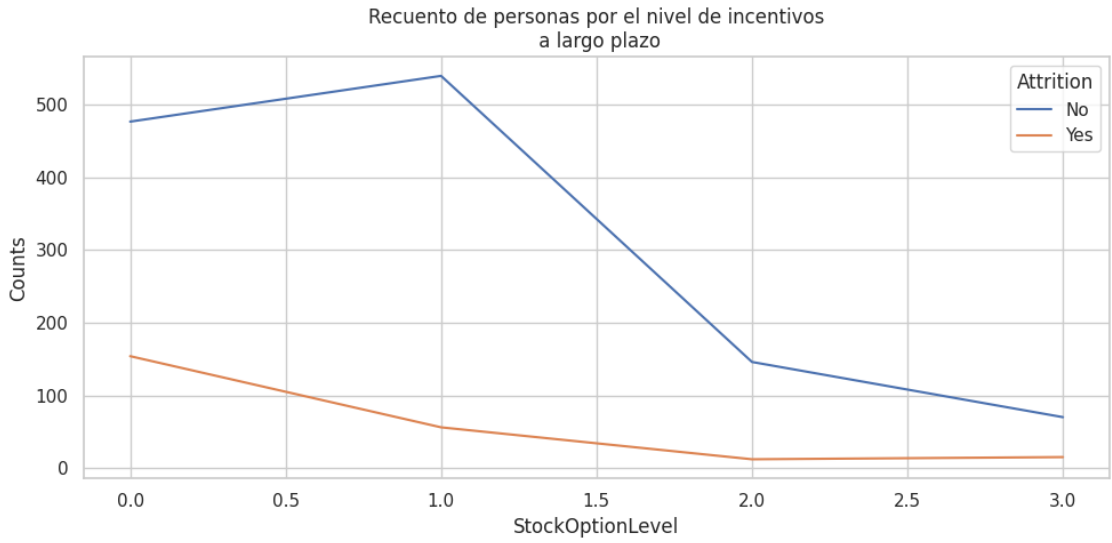

- **Conclusión:** El gráfico muestra una relación inversa con la rotación laboral. Se podría inferir que el personal sin opciones a incentivos a largo plazo (utilidades, planes de carrera, etc) presentan la mayor proporción de rotación, mientras que en niveles altos la rotación es mínima.

1.6.2 ¿Cómo influye la edad en la tasa de rotación?

[32]:
```
age_attrition = df.groupby(["Age","Attrition"])["DailyRate"].size().
 ↪reset_index(name="Counts")
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data=age_attrition, x="Age", y="Counts", hue="Attrition", ax=ax)
ax.set_title("Recuento de personas por edad")
ax.grid(True)
ax.set_xticks(np.arange(20, 60, 5))
fig.tight_layout()
plt.show()
```

Conclusión: Como se observa en el gráfico, la rotación de personal es máxima entre los grupos de edad de 28 a 32 años. Esta tasa disminuye con la edad, ya que se infiere que con mas edad buscan estabilidad laboral en esa etapa. Asimismo, a edades más tempranas, entre los 18 y los 20 años, la probabilidad de que un empleado abandone la organización es mucho mayor, dado que se encuentra en una etapa de exploración, alcanzando un equilibrio a los 21 años.

1.6.3 ¿Son los ingresos el factor principal que influye en la rotación de personal?

[33]:
```
df['MonthlyIncome_round'] = round(df['MonthlyIncome'], -3)
income_attrition = (df.groupby(['MonthlyIncome_round', 'Attrition']).size().
 ↪reset_index(name='Counts'))
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data= income_attrition, x="MonthlyIncome_round", y="Counts",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Cantidad de ingreso mensual")
ax.grid(True)
plt.show()
```

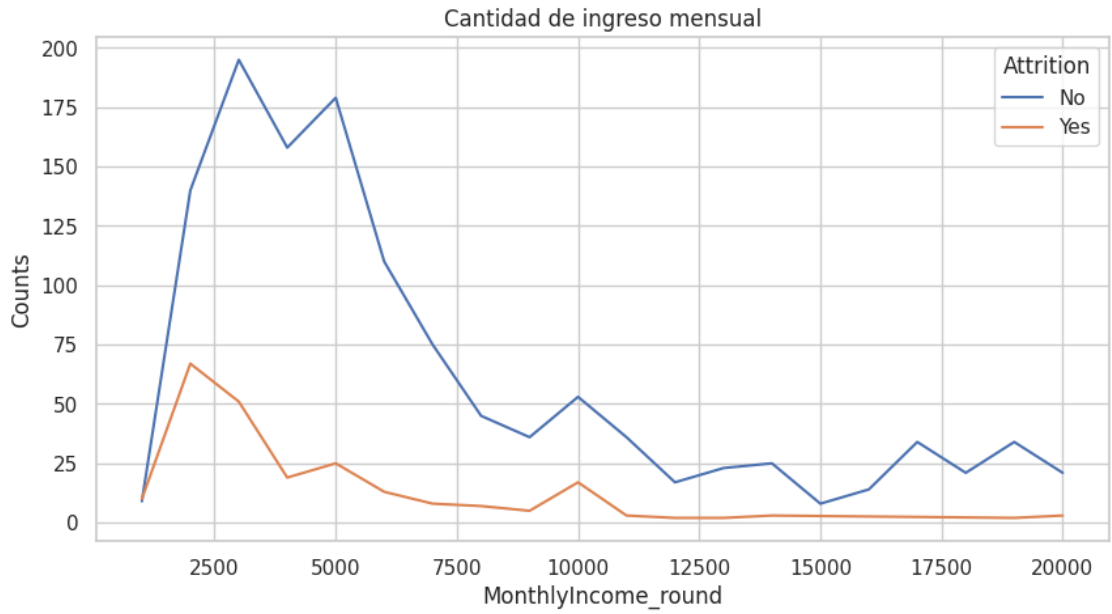

Observación: Como se observa en el gráfico, la tasa de rotación es evidentemente alta en niveles de ingresos muy bajos (menos de 5000 al mes). Esta tasa disminuye aún más, pero se observa un ligero repunte alrededor de los 10 000. Se podría inferir que estas personas tienden a buscar un mejor nivel de vida y, por lo tanto, cambian de trabajo. Cuando el ingreso mensual asciende en una forma razonable, las probabilidades de que un empleado abandone la organización son bajas, como se aprecia en la línea plana.

1.6.4 ¿Influye el Departamento de Trabajo en la rotación de personal?

[34]:
```
dept_attrition = df.groupby(["Department","Attrition"])["DailyRate"].size().
 ↪reset_index(name="Count")
dept_attrition["Pctje"] = round(dept_attrition["Count"] / dept_attrition.
 ↪groupby("Department")["Count"].transform("sum") * 100, 2)
print(dept_attrition)
fig, ax = plt.subplots(figsize=(10, 5))
graf = sns.barplot(data=dept_attrition, x="Department", y="Pctje",␣
 ↪hue="Attrition", ax=ax)
for values in ax.containers:
    ax.bar_label(values, fmt="%.3f%%")
ax.set_title("Recuento de personas por departamento")
fig.tight_layout()
plt.show()
```

```
               Department Attrition  Count  Pctje
0          Human Resources        No     51  80.95
1          Human Resources       Yes     12  19.05
2  Research & Development        No    828  86.16
```

```
3  Research & Development       Yes    133  13.84
4                   Sales        No    354  79.37
5                   Sales       Yes     92  20.63
```

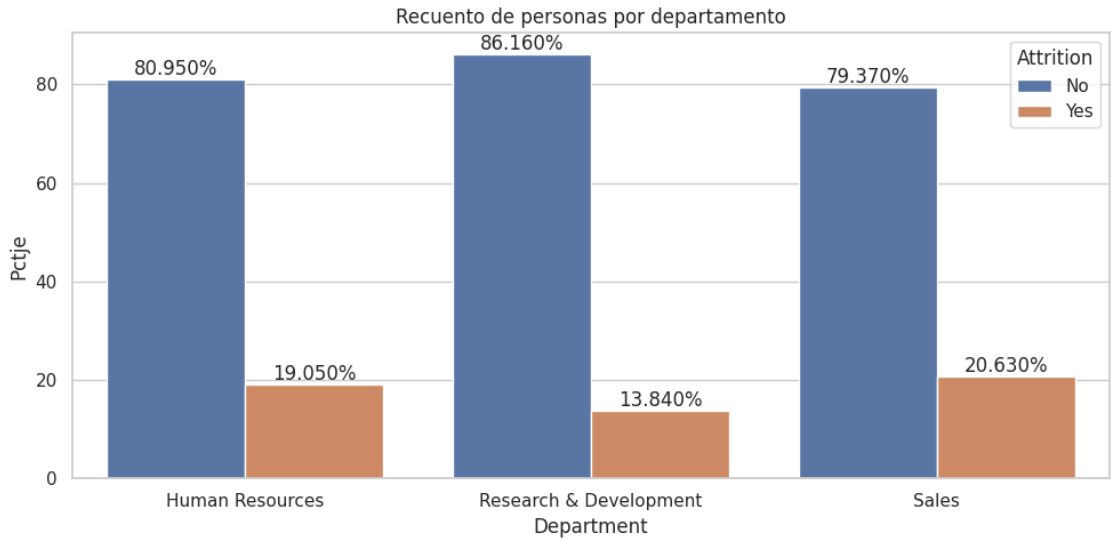

Observaciones: Estos datos solo comprenden tres departamentos principales, entre los cuales el departamento de Ventas presenta la mayor tasa de rotación (20.630%), seguido por el departamento de Recursos Humanos (19.050%). El departamento de Investigación y Desarrollo tiene la menor tasa de rotación, lo que infiere la estabilidad del departamento, como se puede apreciar en el gráfico.

1.6.5 ¿Cómo influye la satisfacción laboral en la rotación de personal?

[35]:
```
jsats_attrition = df.groupby(["JobSatisfaction","Attrition"])["DailyRate"].
 ↪size().reset_index(name="Count")
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data=jsats_attrition, x="JobSatisfaction", y="Count",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Niveles de satisfacción laboral")
ax.grid(True)
plt.show()
```

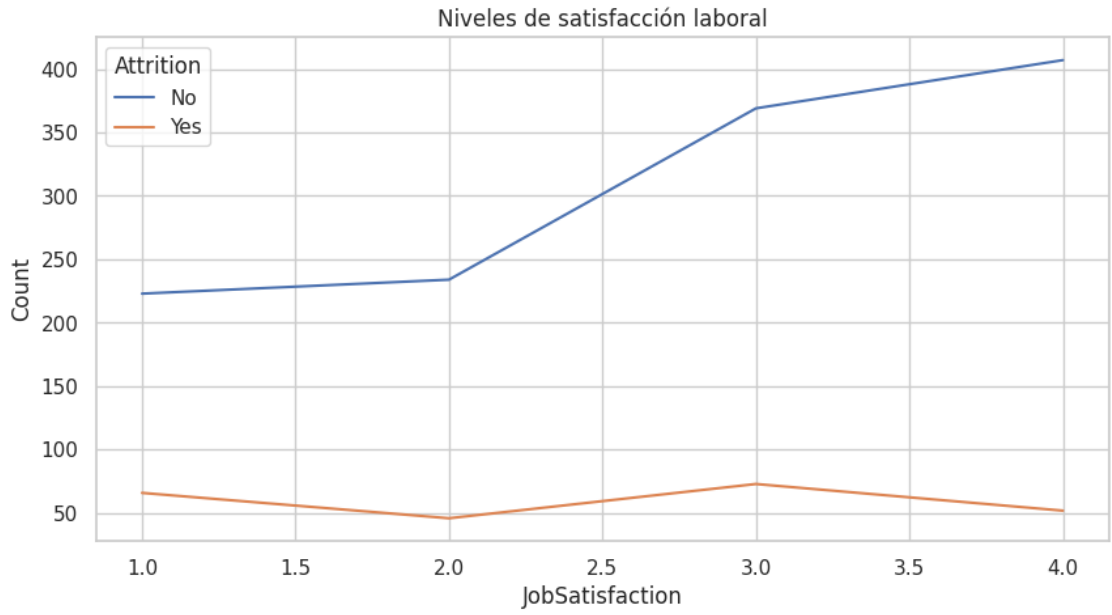

Observación: Con una mayor satisfacción laboral, las tasas de rotación disminuyen, como se puede apreciar en el gráfico. Asimismo, en el rango 1-2 se puede inferir (como se observa en la Satisfacción con el Entorno), que el nivel de rotación disminuye, pero aumenta en el rango 2-3, donde las personas tienden a buscar mejores oportunidades.

1.6.6 ¿Cómo influye la duración del empleo en el puesto actual en la rotación de personal?

[36]:
```
yrscr_attrition = df.groupby(["YearsInCurrentRole", "Attrition"])["DailyRate"].
 ↪size().reset_index(name="Count")
fig, ax = plt.subplots(figsize=(10, 5))
sns.lineplot(data=yrscr_attrition, x="YearsInCurrentRole", y="Count",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Recuento de personas trabajando durante años")
ax.grid(True)
plt.show()
```

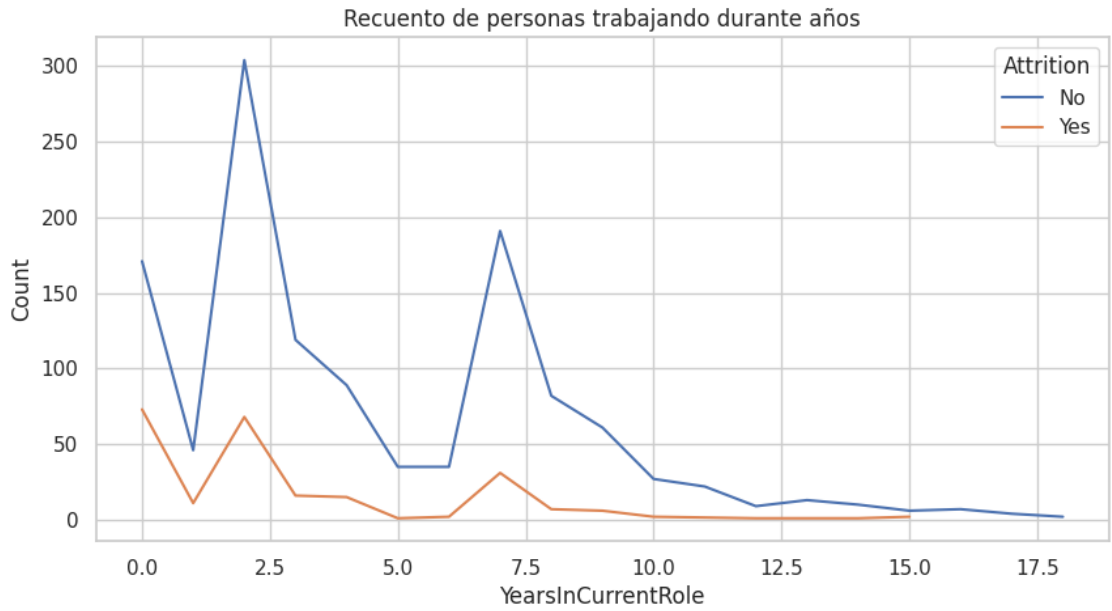

Observación: Se observa que las personas son más propensas a abandonar la organización durante los primeros años en su puesto. Se podría inferir que cuando las personas desempeñan el mismo puesto durante un período prolongado, tienden a permanecer más tiempo para ascender a un puesto superior.

1.6.7 ¿El porcentaje de aumento influye en la rotación de personal?

[37]:
```
hike_attrition = df.groupby(["PercentSalaryHike","Attrition"])["DailyRate"].
 ↪size().reset_index(name="Count")
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data=hike_attrition, x="PercentSalaryHike", y="Count",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Recuento de porcentajes de aumento de salario")
ax.grid(True)
plt.show()
```

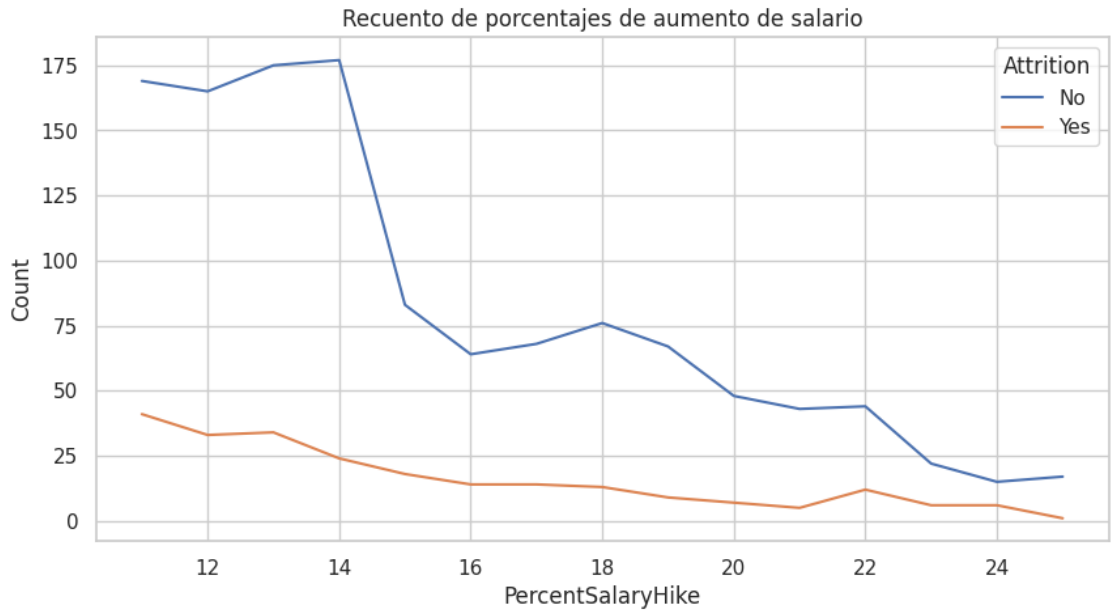

Observación: Los aumentos salariales más altos motivan a las personas a trabajar mejor y a permanecer en la organización. Por lo tanto, vemos que las probabilidades de que un empleado abandone la organización donde el aumento es menor son mucho mayores que en una empresa que ofrece un buen aumento.

1.6.8 ¿Son los gerentes una de las razones por las que la gente renuncia?

[38]:
```
man_attrition = df.groupby(["YearsWithCurrManager", "Attrition"])["DailyRate"].
 ↪size().reset_index(name="Count")
fig, ax = plt.subplots(figsize=(10,5))
sns.lineplot(data=man_attrition, x="YearsWithCurrManager", y="Count",␣
 ↪hue="Attrition", ax=ax)
ax.set_title("Recuento de personas que pasan años con un gerente")
ax.grid(True)
plt.show()
```

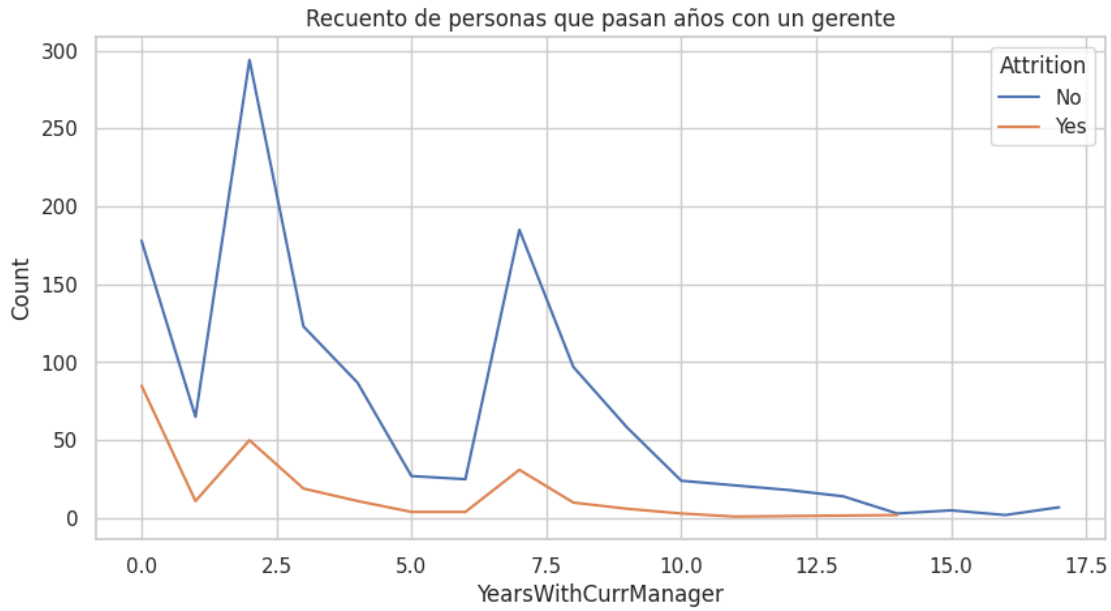

Observación: Se muestra tres picos en la tasa de rotación al analizar la relación de un empleado con su gerente. Al principio, cuando el tiempo con el gerente es relativamente corto, las personas tienden a dejar sus trabajos, infiriendo que consideran su relación con sus gerentes anteriores. En un promedio de dos años, cuando los empleados sienten que necesitan mejorar, también tienden a buscar un cambio. Cuando el tiempo con el gerente es un poco mayor (alrededor de siete años), las personas tienden a sentir que su progresión profesional se estanca y tienden a buscar un cambio. Pero cuando el tiempo relativo con un gerente es muy largo, las personas están satisfechas con su trabajo. Por lo tanto, las probabilidades de que un empleado renuncie en ese momento son significativamente bajas.

1.7 Explorando la distribución de las variables numéricas

[39]:
```
import numpy as np
num_columns = df.select_dtypes(include=np.number).columns
fig, ax = plt.subplots(5, 6, figsize=(30,30))
ax = ax.flat
for i, c in enumerate(num_columns):
    sns.boxplot(data=df, y=c, ax=ax[i])
    ax[i].set_title(c)
fig.tight_layout()
plt.show()
```

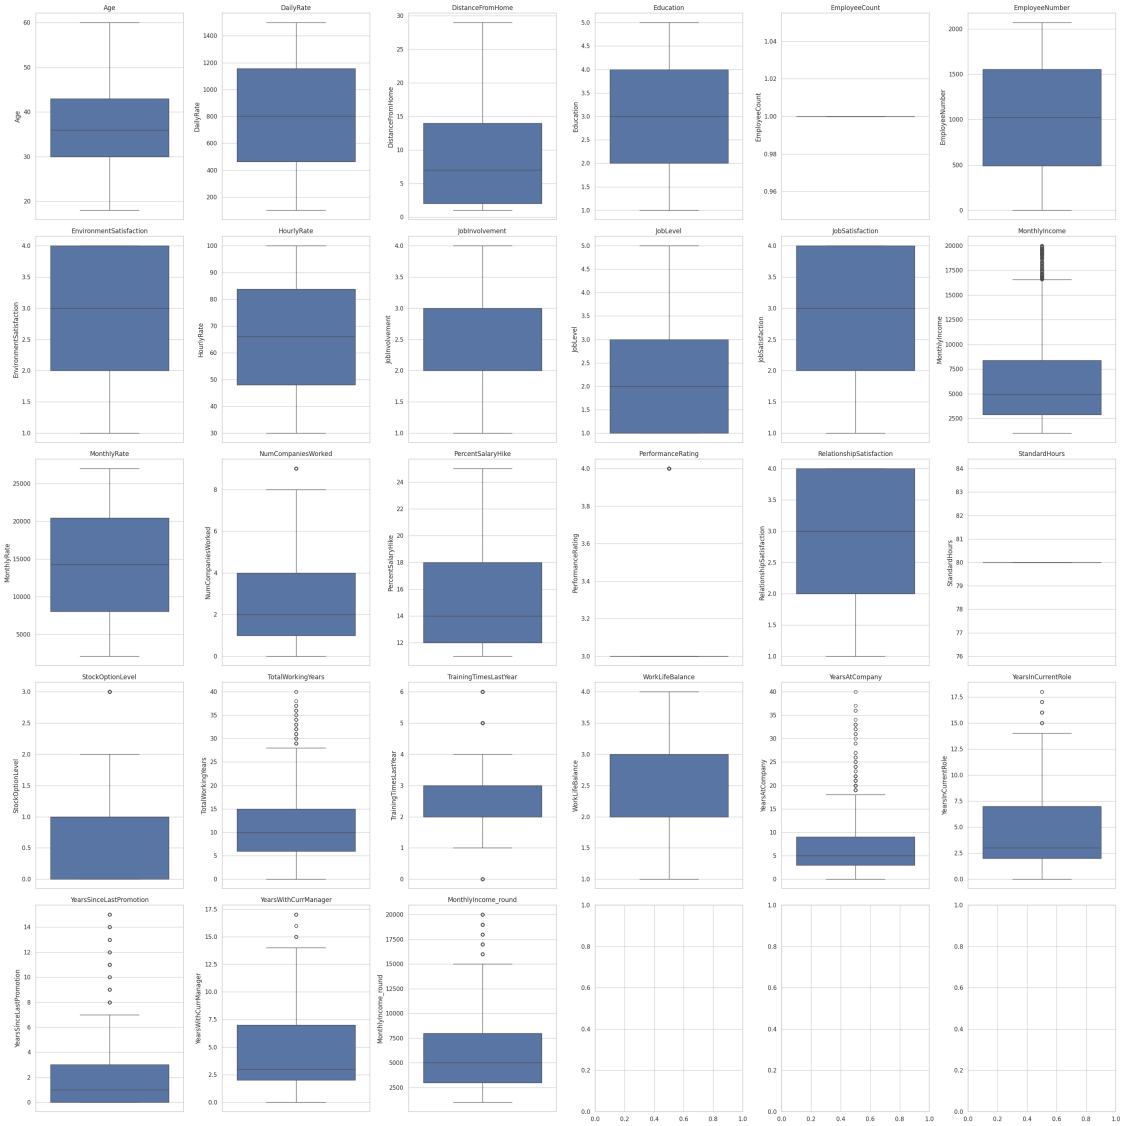

1.8 Separamdo las muestras de entrenamiento y prueba

[40]:
```
X = df.drop(["Attrition", "MonthlyIncome_round"], axis=1)
y = df["Attrition"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)
```

1.9 Balanceo de las clases

[41]:
```
cat_columns_train = X_train.select_dtypes(exclude=np.number).columns
cat_idx = [X_train.columns.get_loc(c) for c in cat_columns_train]

smotec = SMOTENC(categorical_features = cat_idx, random_state=42)
X_train_smote, y_train_smote = smotec.fit_resample(X_train, y_train)
y_train_smote.value_counts()
```

[41]:
```
Attrition
No     986
Yes    986
Name: count, dtype: int64
```

1.10 Preprocesamiento de datos

[42]:
```
num_columns = X_train_smote.select_dtypes(include=np.number).columns
cat_columns = X_train_smote.select_dtypes(exclude=np.number).columns

preprocessor = ColumnTransformer([
    ("scaler", StandardScaler(), num_columns),
    ("ohe", OneHotEncoder(handle_unknown="ignore"), cat_columns)
])
```

1.11 Optimización de hiperparámetros con Optuna

[43]:
```
optuna.logging.set_verbosity(optuna.logging.WARNING)

cv = StratifiedKFold(
    n_splits=5,
    shuffle=True,
    random_state=42
)

def objective(trial):
    pipeline = Pipeline([
        ("preprocessor", preprocessor),
        ("rf", RandomForestClassifier(
            n_estimators = trial.suggest_int("rf__n_estimators", 100, 500),
            max_depth = trial.suggest_int("rf__max_depth", 2, 20),
            min_samples_split = trial.suggest_int("rf__min_samples_split", 2,␣
 ↪10),
            min_samples_leaf = trial.suggest_int("rf__min_samples_leaf", 1, 5),
            max_features = trial.suggest_categorical("rf__max_features",␣
 ↪["sqrt", "log2"]
            ),
            random_state = 42,
```

```
            n_jobs = -1
        ))
    ])
    score = cross_val_score(
        pipeline,
        X_train_smote,
        y_train_smote,
        cv=5,
        scoring="recall_macro",
        n_jobs=-1
        ).mean()
    return score

sampler = optuna.samplers.TPESampler(seed=42)
study = optuna.create_study(direction="maximize", sampler=sampler)
study.optimize(objective, n_trials=50)
```

1.12 Entrenamiento del modelo con los hiperparámetros optimizados

[44]:
```
best_pipeline = Pipeline([
    ("preprocessor", preprocessor),
    ("rf", RandomForestClassifier(random_state=42, n_jobs=-1))
])

best_pipeline.set_params(**study.best_params)
best_pipeline.fit(X_train_smote, y_train_smote)
```

[44]:
```
Pipeline(steps=[('preprocessor',
                 ColumnTransformer(transformers=[('scaler', StandardScaler(),
                                                  Index(['Age', 'DailyRate',
'DistanceFromHome', 'Education', 'EmployeeCount',
       'EmployeeNumber', 'EnvironmentSatisfaction', 'HourlyRate',
       'JobInvolvement', 'JobLevel', 'JobSatisfaction', 'MonthlyIncome',
       'MonthlyRate', 'NumCompaniesWorked', 'PercentSalaryHike',
       'PerformanceRa…
       'YearsSinceLastPromotion', 'YearsWithCurrManager'],
      dtype='object')),
                                                 ('ohe',
OneHotEncoder(handle_unknown='ignore'),
                                                  Index(['BusinessTravel',
'Department', 'EducationField', 'Gender', 'JobRole',
       'MaritalStatus', 'Over18', 'OverTime'],
      dtype='object'))])),
                 ('rf',
                  RandomForestClassifier(max_depth=17, max_features='log2',
                                         min_samples_split=3, n_estimators=302,
                                         n_jobs=-1, random_state=42))])
```

1.13 Variables que mejoran la capacidad del modelo para predecir la (Rotación)

- Cabe resaltar que el atributo `.feature_importances` indica las variables que contribuyen en mayor medida a la capacidad predictiva del modelo orientado a la Rotación.

[45]:
```
features_importances = best_pipeline["rf"].feature_importances_
features_names = best_pipeline["preprocessor"].get_feature_names_out()
features_names = [x.replace("scaler__", "").replace("ohe__", "") for x in␣
 ↪features_names]
features_importances = pd.DataFrame({"feature": features_names,
                                     "value": features_importances}).
 ↪sort_values("value", ascending=False)[:7]
features_main = ["Incentivos largo plazo","Ingreso mensual","Satisf.␣
 ↪laboral","Edad","Involucramiento","Antiguedad","Nivel jerarquico"]
fig, ax = plt.subplots(figsize=(10,6))
sns.barplot(data=features_importances, x=features_main, y="value", ax=ax)
ax.set_title("Principales variables que contribuyen la\n capacidad predictiva␣
 ↪de rotación")
ax.tick_params(axis='x', rotation=45)
fig.tight_layout()
plt.show()
```

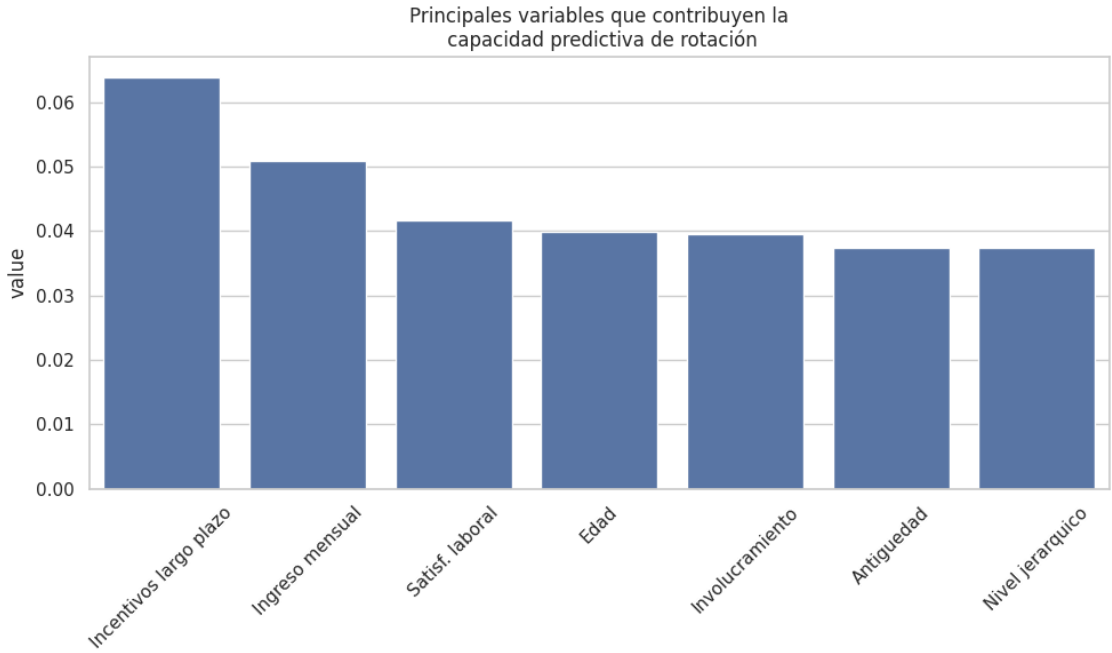

1.13.1 Interpretación individual de las variables con mas importancia

1. **StockOptionLevel (0.063889)** —> variable más influyente

- Incentivos a largo plazo (ganancia de utilidades, planes de carrera, etc)

- El empleado solo se beneficia si pertenece.
- Siendo una estrategia clave de retención, incluso se podría inferir que es más relevante que el salario directo.

2. **MonthlyIncome (0.050812)**

- El ingreso mensual es el segundo factor más importante
- Salarios más bajos → mayor probabilidad de rotación

3. **JobSatisfaction (0.041572)**

- Es la variable actitudinal fundamental.
- Menor satisfacción laboral aumenta significativamente el riesgo de rotación.
- Inferiendo que el modelo no se basa solo en variables económicas, sino también en percepciones del empleado.

4. **Age (0.039906)**

- Variable demográfico influyente.
- Empleados más jóvenes suelen presentar:
  - mayor disposición al cambio laboral

5. **JobInvolvement (0.039500)**

- Mide el nivel de compromiso con el trabajo
- Bajo involucramiento → mayor riesgo de Attrition

6. **TotalWorkingYears (0.037393)**

- Experiencia laboral acumulada
- Empleados con más años de experiencia:
  - tienden a la estabilidad
  - presentan menor rotación

1.14 Gráfico del árbol de decisión mas influyente

[46]:
```
from sklearn.tree import plot_tree

trees = [tree.feature_importances_ for tree in best_pipeline["rf"].estimators_]
# promedio de cada árbol
mean_importances = np.mean(trees, axis=1)
most_important_tree_idx = np.argmax(mean_importances)
most_important_tree = best_pipeline["rf"].estimators_[most_important_tree_idx]

plt.figure(figsize=(150,30))
plot_tree(most_important_tree, filled=True, feature_names=features_names,␣
 ↪class_names=best_pipeline.classes_)
plt.show()
```

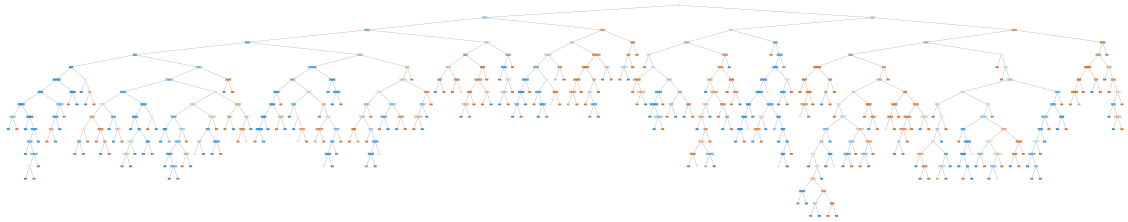

1.15 Métricas de clasificación

[47]:
```
y_predict = best_pipeline.predict(X_test)
print(classification_report(y_test, y_predict))
```

```
              precision    recall  f1-score   support

          No       0.90      0.93      0.91       247
         Yes       0.55      0.45      0.49        47

    accuracy                           0.85       294
   macro avg       0.73      0.69      0.70       294
weighted avg       0.84      0.85      0.85       294
```

Conclusiones: El modelo fue evaluado con la muestra de prueba el cual consistía de 294 empleados, obteniendo una exactitud (accuracy) del 85%, lo que indica en términos generales que tiene un buen desempeño. Sin embargo debe considerarse el desbalance de clases (muchos más casos "No" que "Yes").

Interpretación por clase

- **Clase No (empleados que no rotan)**
  - **Precision:** 0.90
    El 90% de los empleados que el modelo predice como "No rotan" efectivamente no rotan.
    El modelo es confiable para identificar personal estable.
  - **Recall:** 0.93
    El modelo identifica correctamente al 93% de todos los empleados que realmente no rotan.
    Muy pocos empleados estables son clasificados erróneamente como rotación.
  - **F1-score:** 0.91 Indica un buen equilibrio entre precisión y recall para esta clase.

Conclusión: El modelo muestra buenas métricas para detectar empleados que permanecerán en la organización.

- **Clase Yes (empleados que sí rotan)**
  - **Precision:** 0.55

    Solo el 54% de los empleados predichos como "rotación" realmente terminan rotando.

    Existe una tasa considerable de falsos positivos.

- **Recall:** 0.45

  El modelo identifica únicamente al 45% de los empleados que efectivamente rotan.

  Más de la mitad de los casos reales de rotación no son detectados.

- **F1-score:** 0.49

  Refleja un bajo equilibrio entre precisión y recall para esta clase.

Conclusión: El modelo tiene dificultades para identificar correctamente a los empleados en riesgo de rotación.

1.16 Matriz de confusión

[48]:
```
fig, ax = plt.subplots(figsize=(5,5))
cm = confusion_matrix(y_test, y_predict)
ConfusionMatrixDisplay(cm, display_labels=best_pipeline.classes_).plot(ax=ax)
plt.xticks(rotation=45)
plt.show()
```

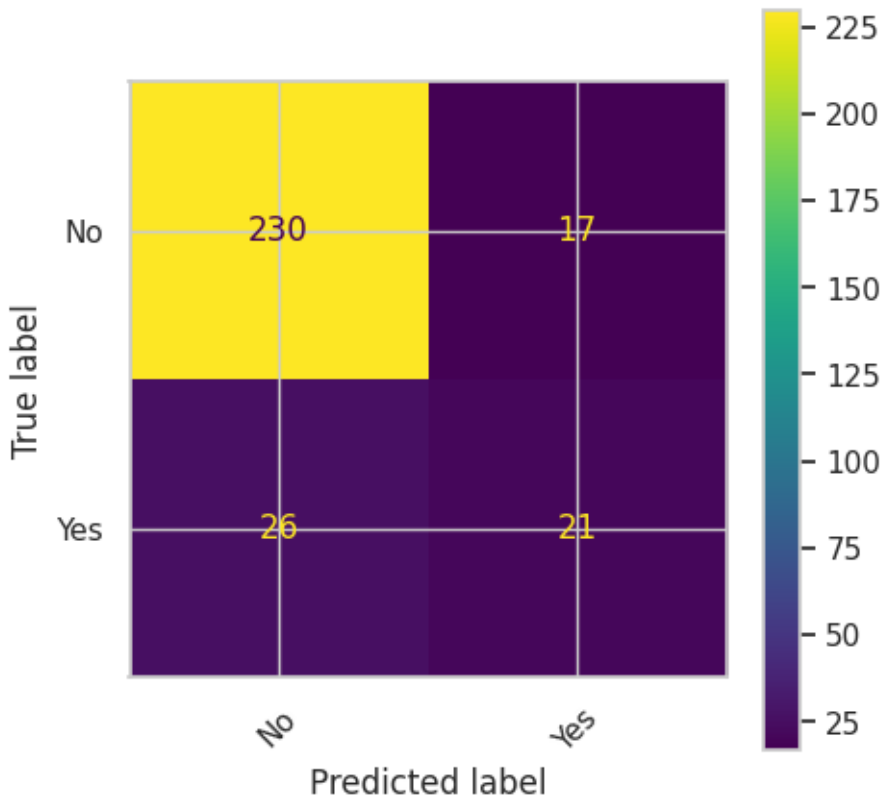

Verdaderos Negativos (230)

Empleados que NO rotaron y el modelo predijo NO rotan. - Muy buen desempeño aquí.

El modelo es confiable identificando empleados estables.

Falsos Positivos (17)

Empleados que NO rotaron, pero el modelo predijo que SÍ rotarían. Consecuencia práctica:

- RH podría gastar recursos innecesarios (retención, incentivos) en empleados que no se iban a ir.

Falsos Negativos (26)

Empleados que SÍ rotaron, pero el modelo predijo que NO rotarían. Este es el mayor problema del modelo. Consecuencia práctica:

- La empresa no detecta a tiempo empleados en riesgo, y los pierde sin intervención.

Verdaderos Positivos (21)

Empleados que SÍ rotaron y el modelo predijo correctamente que SÍ rotarían. - Estos casos sí permiten acciones preventivas.

1.17 Curva ROC

[49]:
```
le = LabelEncoder()
y_train_le = le.fit_transform(y_train_smote)
y_test_le = le.transform(y_test)

y_proba = best_pipeline.predict_proba(X_test)[:,1]
r_fpr, r_tpr, _ = roc_curve(y_test_le, y_proba)
roc_auc = auc(r_fpr, r_tpr)
```

[50]:
```
fig, ax = plt.subplots(figsize=(7, 7))
sns.lineplot(x=r_fpr, y=r_tpr, color="blue", label=f"AUC = {roc_auc:.2f}",␣
 ↪ax=ax)
ax.plot([0,1], [0,1], "k--", label="Azar")
ax.set_xlabel('FPR (Tasa de Falsos Positivos)')
ax.set_ylabel('TPR (Tasa de Verdaderos Positivos)')
ax.set_title('Curva ROC')
ax.grid(True)
fig.tight_layout()
plt.show()
```

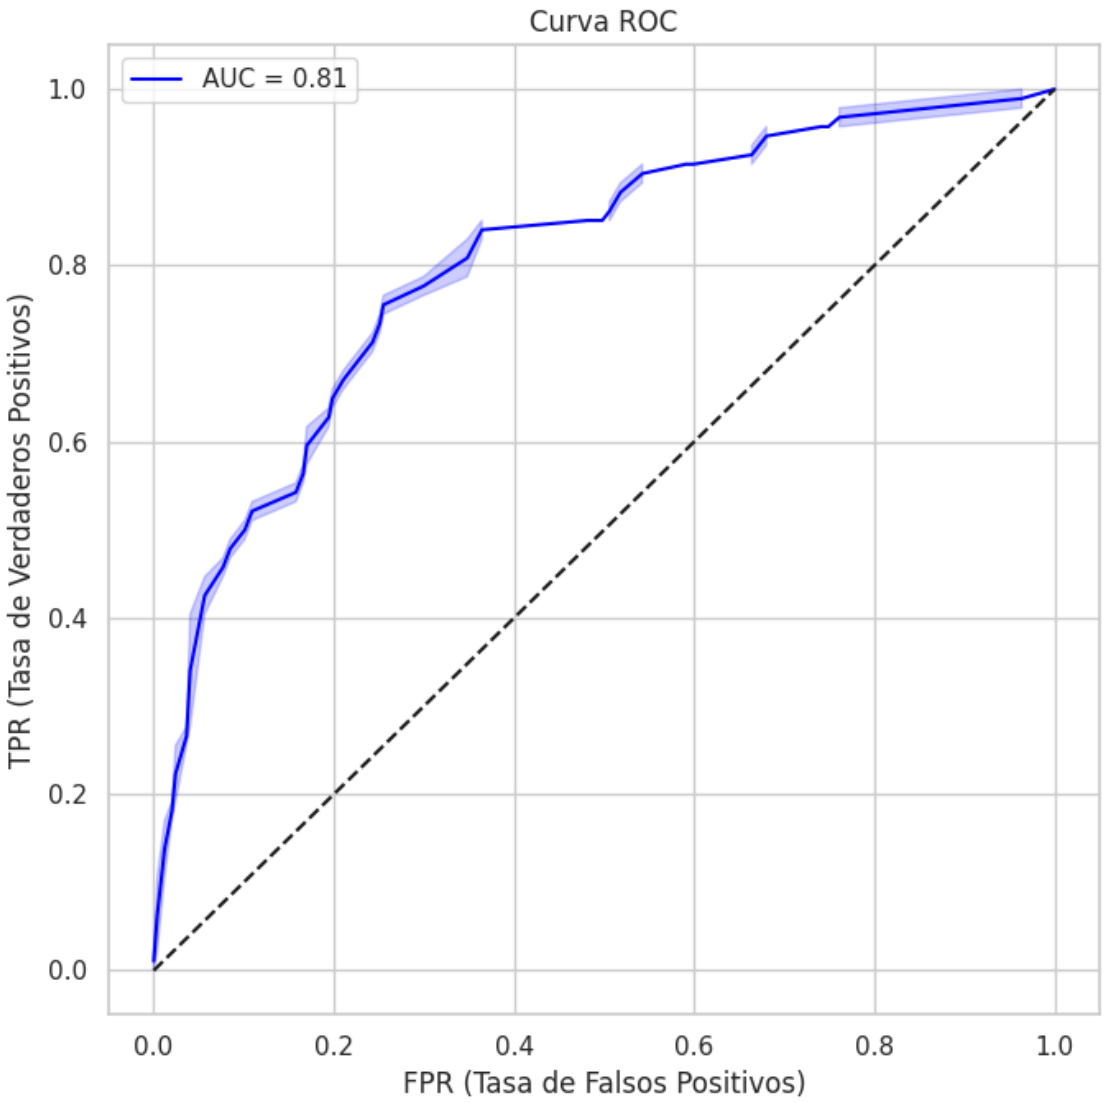

Concluisón: La curva ROC muestra una buena capacidad de descriminación del modelo **(AUC = 0.81)**, lo cual se infiere que puede diferenciar razonablemente entre empleados que rotan y no rotan. Sin embargo, el umbral de clasificación prioriza la identificación de empleados estables (NO rotan), reduciendo la posibilidad de detectar casos de rotación, lo cual podría limitar su funcionalidad preventiva.